

Relatório do Projeto da UC de Análise e Visualização de Dados

DOCENTES: ALVARO IRIARTE | JOSÉ JOÃO

Realizado por: Inês Catarina Teixeira Leão | PG50855

Mestrado em Humanidades Digitais

Conteúdo

Introdução	2
Sumário Executivo	2
Objeto do relatório	3
Caderno de campo	3
1. A Mulher Fatal	3
1.1 Entidades	4
1.2 Análise de Sentimento	6
1.3 Lemas	9
1.4 Lugares	13
2. Amor de Salvação	16
2.1 Verbos	16
2.2 Análise de Sentimento	18
2.3 Palavras-Chave	21
2.4 Lugares	24
3. O Romance de Um Homem Rico	26
3.1 Entidades	26
3.2 Adjetivos	29
3.3 Lemas	30
3.4 Análise de Sentimento	33
4. Onde está a Felicidade?	37
4.1 Palavras-Chave	37
4.2 Advérbios	39
4.3 Verbos	40
4.4 Análise de Sentimento	43
Conclusão	48
Bibliografia	49

Introdução

Este relatório apresenta os resultados de um trabalho de análise e visualização de dados realizado com o objetivo de extrair informações pertinentes e insights significativos a partir de conjuntos de dados mais complexos. Neste projeto, adotou-se uma abordagem abrangente para explorar os conjuntos de dados disponíveis, utilizando técnicas avançadas de análise estatística, mineração de dados e visualização interativa. Ao longo deste relatório, serão apresentadas as etapas do processo de análise e visualização de dados, descrevendo as técnicas e ferramentas utilizadas, bem como os principais resultados obtidos. As obras escolhidas foram: "O Romance de um Homem Rico", "A Mulher Fatal", "Amor de Salvação" e "Onde Está a Felicidade?".

Importante referir que as obras se encontram em formato de *one sentence per line*, todos os programas criados.

Sumário Executivo

Este relatório apresenta os resultados de um trabalho de análise e visualização de dados sobre quatro obras de Camilo Castelo Branco: "O Romance de um Homem Rico", "A Mulher Fatal", "Amor de Salvação" e "Onde Está a Felicidade?". O objetivo do estudo foi analisar diversos aspetos das obras, nomeadamente a extração de lemas, identificação de entidades, análise de adjetivos e avaliação de sentimentos em cada capítulo.

Utilizando técnicas de processamento de linguagem natural e programação em Python, foram aplicadas bibliotecas como *SpaCy* e *NLTK* para realizar a análise dos dados.

obra, como tristeza, alegria, melancolia ou raiva, contribuindo para uma análise mais abrangente do tom emocional presente nos textos.

Estas análises e visualizações dos dados fornecem uma visão detalhada das características linguísticas, temáticas e emocionais presentes nas obras de Camilo Castelo Branco, aqui trabalhadas. Os resultados obtidos podem ser usados para *insights* adicionais sobre o estilo de escrita do autor, por exemplo, a evolução dos personagens ao longo das histórias e os temas abordados nas obras.

Ademais, note-se que a compreensão destes elementos permite uma apreciação mais profunda das obras de Camilo Castelo Branco, bem como o enriquecimento da crítica literária e estudos comparativos dos seus trabalhos. Além disso, essas análises e visualizações podem servir de base para futuras pesquisas e estudos relacionados à obra do autor. Este relatório além de apresentar os resultados relevantes da análise, acaba por destacar por si só a importância da análise e visualização de dados para a compreensão e apreciação da literatura.

Objeto do relatório

O objeto do relatório é fornecer uma análise detalhada e abrangente das quatro obras de Camilo Castelo Branco: "O Romance de um Homem Rico", "A Mulher Fatal", "Amor de Salvação" e "Onde Está a Felicidade?". O relatório tem como objetivo principal investigar e extrair informações relevantes a partir dos dados contidos nessas obras, utilizando técnicas de análise de texto, processamento de linguagem natural e análise de sentimentos.

Caderno de campo

O caderno de campo desempenha um papel fundamental no trabalho de Análise e Visualização de Dados (AVD) realizado com as obras de Camilo Castelo Branco. Este documento serve como um registo detalhado das atividades, observações e descobertas feitas durante a análise dos dados extraídos das obras selecionadas: "O Romance de um Homem Rico", "A Mulher Fatal", "Amor de Salvação" e "Onde Está a Felicidade?". Este documenta as técnicas e ferramentas utilizadas para a extração de dados presentes em cada obra. Ao longo deste documento, se registadas as decisões metodológicas, as dificuldades encontradas e as observações relevantes que surgirem durante a análise dos dados.

1. A Mulher Fatal

Para esta obra, foi analisado e extraído as entidades do texto, as localidades, os lemas e feita uma análise de sentimento por cada capítulo do livro. O documento de texto que contém a obra, foi utilizado sempre em formato de *one sentence per line*.

1.1 Entidades

Para extrair as entidades da obra *A mulher fatal*, utilizei o seguinte programa *Python*, utilizando a biblioteca *spaCy*

```
1 import spacy
2 import os
3 import csv
4
5 with open('a_mulher_fatal1spl.txt', 'r', encoding='UTF-8') as file:
6     text = file.read()
7
8 nlp = spacy.load('pt_core_news_sm')
9 doc = nlp(text)
10
11 characters = []
12
13 for ent in doc.ents:
14     if ent.label_ == "PER":
15         characters.append(ent.text)
16
17 from collections import Counter
18
19 characters_counts = Counter(characters)
20
21 top30_characters = characters_counts.most_common(30)
22
23 print(top30_characters)
24
25 with open('Entidades_amulherfatal.csv', 'w', newline='') as file:
26     writer = csv.writer(file)
27     writer.writerow(['Personagem', 'Contagem']) # Adiciona o cabeçalho das colunas
28
29     for character, count in top30_characters:
30         writer.writerow([character, count])
```

Este programa extrairá um Top 30 personagens, juntamente com o número de vezes que cada uma surge. O programa cria um documento *csv* com os resultados:


	Personagem	Contagem						
1								
2	Carlos	172						
3	Carlos Pereira	34						
4	Vossa Excelência	32						
5	Filomena	31						
6	Deus	22						
7	Esteia	16						
8	Eduardo	15						
9	Vossa Senhoria	10						
10	Laura	9						
11	Olhe	8						
12	Fui	8						
13	Quero	7						
14	Luís	5						
15	João de Campos	5						
16	Tenho	5						
17	Joaquim das Neves	5						
18	Antunes	5						
19	Espero	4						

18	Antunes	5						
19	Espero	4						
20	Narcisa	4						
21	Querem	4						
22	Voltaire	3						
23	Paulo de Carvall	3						
24	Júlia	3						
25	Ali	3						
26	Diga	3						
27	Ouvi	3						
28	Carlos Pereira	3						
29	conde de ***	3						
30	Virgílio	2						
31	Satã	2						
32								
33								

Em seguida, prossegui com uma limpeza manual ao documento, deixando apenas os resultados relevantes para o que são as personagens do livro. Assim:

	A	D	C	U	E	F	G	N
1	Personagem	Contagem						
2	Carlos Pereira	209						
3	Filomena	31						
4	Deus	22						
5	Esteia	16						
6	Eduardo	15						
7	Laura	9						
8	Luís	5						
9	João de Campos	5						
10	Joaquim das Ne	5						
11	Antunes	5						
12	Narcisa	4						
13	Voltaire	3						
14	Paulo de Carvall	3						
15	Júlia	3						
16	Virgílio	2						
17								
18								
19								

Por fim, criei um gráfico de barras como proposta de visualização. Na figura abaixo:



1.2 Análise de Sentimento

Para fazer a análise de sentimento de cada capítulo, criei o seguinte programa *Python*, que utiliza a biblioteca *NLTK* (*Natural Language Toolkit*) para realizar uma análise de sentimentos num dado texto. Ele utiliza o módulo *'SentimentIntensityAnalyzer'* do *NLTK*, que é responsável por atribuir pontuações de sentimento a diferentes partes do texto.

```
1 import nltk
2 from nltk.sentiment import SentimentIntensityAnalyzer
3
4 nltk.download('vader_lexicon')
5
6 sia = SentimentIntensityAnalyzer()
7
8 caminho_arquivo = "a_mulher_fatal1spl.txt"
9
10 with open(caminho_arquivo, 'r', encoding='utf-8') as arquivo:
11     texto = arquivo.read()
12
13 capitulos = texto.split('# Capítulo')
14
15 for i, capitulo in enumerate(capitulos[1:]):
16     sentiment = sia.polarity_scores(capitulo)
17     print(f"Sentimento do Capítulo {i+1}: {sentiment}")
```

Primeiro, o código importa as bibliotecas necessárias e faz o download do léxico *Vader* do *NLTK*, que é usado para análise de sentimentos. Em seguida, é criada uma instância do *'SentimentIntensityAnalyzer'*.

Depois, o código lê o arquivo *txt* da obra *A mulher fatal* no formato de *one sentence per line* e armazena-o numa variável. O texto é dividido em capítulos usando um marcador específico (no caso, foi colocada um *#* em cada capítulo no documento de texto). Através de um *loop*, cada capítulo é analisado usando o *'SentimentIntensityAnalyzer'*, que retorna uma pontuação de sentimento para aquele capítulo.

Em resumo, o código realiza a análise de sentimentos no texto, dividindo-o em capítulos e calculando a pontuação de sentimento para cada um deles. Os resultados no terminal são:

```

[nltk_data] C:\Users\ines2\AppData\Roaming\nltk_data...
[nltk_data] Package vader_lexicon is already up-to-date!
Sentimento do Capítulo 1: {'neg': 0.03, 'neu': 0.959, 'pos': 0.011, 'compound': -0.9086}
Sentimento do Capítulo 2: {'neg': 0.018, 'neu': 0.968, 'pos': 0.014, 'compound': 0.6836}
Sentimento do Capítulo 3: {'neg': 0.013, 'neu': 0.976, 'pos': 0.01, 'compound': 0.5897}
Sentimento do Capítulo 4: {'neg': 0.014, 'neu': 0.976, 'pos': 0.01, 'compound': -0.703}
Sentimento do Capítulo 5: {'neg': 0.019, 'neu': 0.971, 'pos': 0.01, 'compound': -0.8867}
Sentimento do Capítulo 6: {'neg': 0.022, 'neu': 0.967, 'pos': 0.011, 'compound': -0.9724}
Sentimento do Capítulo 7: {'neg': 0.014, 'neu': 0.978, 'pos': 0.008, 'compound': -0.8413}
Sentimento do Capítulo 8: {'neg': 0.016, 'neu': 0.971, 'pos': 0.013, 'compound': 0.5897}
Sentimento do Capítulo 9: {'neg': 0.024, 'neu': 0.968, 'pos': 0.008, 'compound': -0.9684}
Sentimento do Capítulo 10: {'neg': 0.017, 'neu': 0.974, 'pos': 0.009, 'compound': -0.9836}
Sentimento do Capítulo 11: {'neg': 0.018, 'neu': 0.974, 'pos': 0.008, 'compound': -0.9951}
PS C:\Users\ines2\OneDrive\Ambiente de Trabalho\avd2023\trabalho final avd>

```

Nos resultados exibidos, cada capítulo possui um dicionário de pontuações que indica a intensidade do sentimento positivo, negativo e neutro. Além disso, há o valor do "*compound*".

- '*neg*': pontuação de negatividade do capítulo.
- '*neu*': pontuação de neutralidade do capítulo.
- '*pos*': pontuação de positividade do capítulo.
- '*compound*': pontuação geral do sentimento do capítulo, que é calculada com base nas pontuações anteriores e representa uma medida agregada do sentimento do texto. O valor do *compound* varia de -1 a 1, onde -1 indica um sentimento extremamente negativo, 1 indica um sentimento extremamente positivo e 0 indica neutralidade.

Neste caso, os valores para '*compound*' variam entre -0.9951 e 0.6836. Os valores mais próximos de -1 indicam sentimentos negativos, os valores mais próximos de 1 indicam sentimentos positivos e valores próximos de 0 indicam sentimentos neutros.

Portanto, analisando os resultados, podemos inferir que o Capítulo 1 possui um sentimento negativo mais forte (-0.9086), enquanto o Capítulo 2 possui um sentimento positivo moderado (0.6836). Já o Capítulo 3 também tem um sentimento positivo, porém menos intenso (0.5897).

Para criar uma proposta de visualização, criei o seguinte programa:


```

import matplotlib.pyplot as plt

pontuacoes = [
    {'neg': 0.03, 'neu': 0.959, 'pos': 0.011, 'compound': -0.9086},
    {'neg': 0.018, 'neu': 0.968, 'pos': 0.014, 'compound': 0.6836},
    {'neg': 0.013, 'neu': 0.976, 'pos': 0.01, 'compound': 0.5897},
    {'neg': 0.014, 'neu': 0.976, 'pos': 0.01, 'compound': -0.703},
    {'neg': 0.019, 'neu': 0.971, 'pos': 0.01, 'compound': -0.8867},
    {'neg': 0.022, 'neu': 0.967, 'pos': 0.011, 'compound': -0.9724},
    {'neg': 0.014, 'neu': 0.978, 'pos': 0.008, 'compound': -0.8413},
    {'neg': 0.016, 'neu': 0.971, 'pos': 0.013, 'compound': 0.5897},
    {'neg': 0.024, 'neu': 0.968, 'pos': 0.008, 'compound': -0.9684},
    {'neg': 0.017, 'neu': 0.974, 'pos': 0.009, 'compound': -0.9836},
    {'neg': 0.018, 'neu': 0.974, 'pos': 0.008, 'compound': -0.9951}
]

valores_compound = [sentimento['compound'] for sentimento in pontuacoes]

rotulos = [f"Capítulo {i+1}" for i in range(len(pontuacoes))]

plt.figure(figsize=(10, 6))
plt.bar(rotulos, valores_compound)
plt.xlabel('Capítulo')
plt.ylabel('Sentimento (compound)')
plt.title('Análise de Sentimento por Capítulo')
plt.xticks(rotation=45)
plt.show()


```

O código em questão utiliza a biblioteca Matplotlib em conjunto com os resultados da análise de sentimento por capítulos para criar um gráfico de barras. O objetivo é visualizar a variação do sentimento ao longo dos capítulos de uma obra. Inicialmente, os resultados da análise de sentimento por capítulo são armazenados numa lista chamada `'pontuacoes'`. Cada elemento dessa lista é um dicionário que contém as pontuações de negatividade (`'neg'`), neutralidade (`'neu'`), positividade (`'pos'`) e a pontuação geral do sentimento (`'compound'`) para um capítulo específico.

O próximo passo consiste em extrair os valores do `'compound'` de cada dicionário da lista `'pontuacoes'`. Esses valores são armazenados numa lista separada chamada `'valores_compound'`. Esta lista representa a medida agregada do sentimento para cada capítulo. A lista `'rotulos'` é criada para armazenar os rótulos dos capítulos. Cada rótulo é definido como "Capítulo X", onde X é o número do capítulo correspondente. Com todos os dados necessários preparados, o código utiliza a biblioteca Matplotlib para criar o gráfico de barras. É criada uma figura com um tamanho específico utilizando a função `'plt.figure(figsize=(10, 6))'`. Em seguida, a função `'plt.bar()'` é utilizada para criar as barras do gráfico. Os rótulos dos capítulos são exibidos no eixo x e os valores do compound são representados no eixo y. Algumas funções do Matplotlib, como `'plt.xlabel()'`, `'plt.ylabel()'`, `'plt.title()'` e `'plt.xticks(rotation=45)'`, são utilizadas para adicionar rótulos aos eixos e ao gráfico em geral, além de fazer uma rotação de 45 graus

nos rótulos dos capítulos para facilitar a leitura. Por fim, o gráfico é exibido na tela utilizando a função `plt.show()`.

Assim, o gráfico:



Conclui-se que, na maior parte dos capítulos, o sentimento é negativo.

1.3 Lemas

Para extrair um top 50 lemas da obra, foi criado o seguinte programa:

```

1 import nltk
2 from nltk import FreqDist
3 from nltk.corpus import stopwords
4 from nltk.stem import WordNetLemmatizer
5 import csv
6
7 nltk.download('punkt')
8 nltk.download('stopwords')
9 nltk.download('wordnet')
10
11 def extract_lemmas(text):
12     lemmatizer = WordNetLemmatizer()
13     stop_words = set(stopwords.words('english'))
14
15     tokens = nltk.word_tokenize(text)
16     lemmas = [lemmatizer.lemmatize(token.lower()) for token in tokens if token.isalnum() and token.lower() not
17               in stop_words]
18
19     return lemmas
20
21 def save_lemmas_to_csv(lemmas, output_file):
22     fdist = FreqDist(lemmas)
23     top_lemmas = fdist.most_common(50)
24
25     with open(output_file, 'w', newline='') as csvfile:
26         writer = csv.writer(csvfile)
27         writer.writerow(['Lemma', 'Frequency'])
28         for lemma, freq in top_lemmas:
29             writer.writerow([lemma, freq])
30
31 input_file = 'a_mulher_fatal1spl.txt'
32
33 output_file = 'TOP50a_mulher_fatal.csv'
34
35 with open(input_file, 'r') as file:
36     text = file.read()
37
38 lemmas = extract_lemmas(text)
39
40 save_lemmas_to_csv(lemmas, output_file)

```

O programa utiliza o NLTK para extrair os lemas da obra, carregada em formato de texto, bem como calcula a frequência que cada um aparece no texto. Assim, os 50 lemas mais frequentes são guardados num arquivo novo em formato csv. Tem-se:

	Lemma	Frequency						
1	que	1625						
2	de	1620						
3	e	1219						
4	não	692						
5	da	655						
6	se	506						
7	com	426						
8	em	380						
9	o	374						
10	um	335						
11	eu	321						
12	carlos	303						
13	para	299						
14	é	299						
15	uma	253						
16	ao	236						
17	na	235						
18	por	218						
19								

20	à	214					
21	do	200					
22	ele	180					
23	ma	179					
24	como	179					
25	meu	176					
26	mais	173					
27	sua	166					
28	era	163					
29	lhe	150					
30	seu	145					
31	ano	139					
32	quando	135					
33	ela	131					
34	minha	117					
35	amigo	108					
36	cassilda	106					
37	onde	104					
38	ou	103					

39	muito	99					
40	mulher	95					
41	há	95					
42	senhora	95					
43	disse	92					
44	quem	91					
45	nem	91					
46	te	85					
47	día	85					
48	coração	84					
49	já	83					
50	ainda	80					
51	no	79					
52							

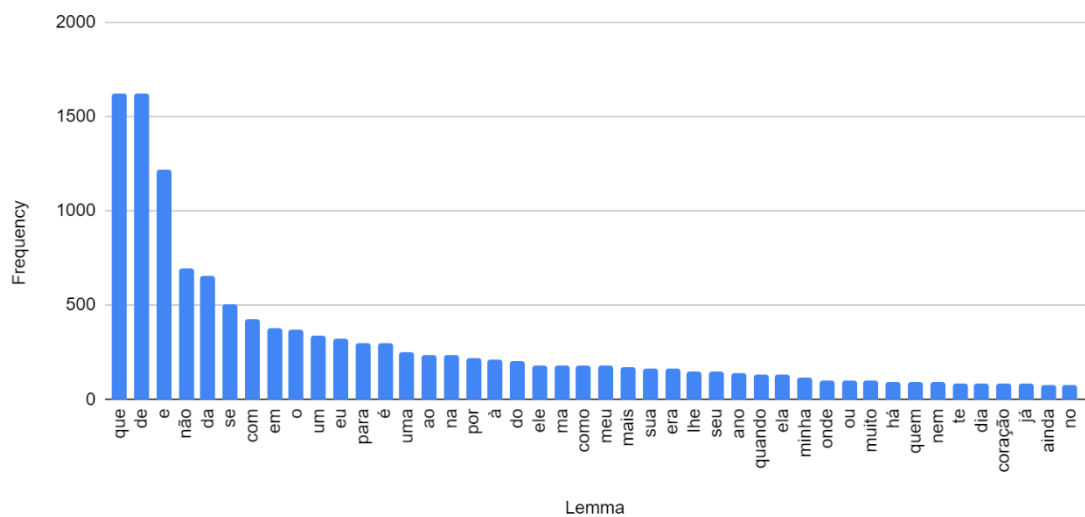
Depois, procedi à limpeza manual do mesmo. Resultou:

1	Lemma	Frequency					
2	que	1625					
3	de	1620					
4	e	1219					
5	não	692					
6	da	655					
7	se	506					
8	com	426					
9	em	380					
10	o	374					
11	um	335					
12	eu	321					
13	para	299					
14	é	299					
15	uma	253					
16	ao	236					
17	na	235					
18	por	218					
19	à	214					

20	do	200							
21	ele	180							
22	ma	179							
23	como	179							
24	meu	176							
25	mais	173							
26	sua	166							
27	era	163							
28	lhe	150							
29	seu	145							
30	ano	139							
31	quando	135							
32	ela	131							
33	minha	117							
34	onde	104							
35	ou	103							
36	muito	99							
37	há	95							
38	quem	91							
39	nem	91							
40	te	85							
41	dia	85							
42	coração	84							
43	já	83							
44	ainda	80							
45	no	79							
46									
47									
48									
49									
50									
51									

Como proposta de visualização, criei o seguinte gráfico:

LEMMAS



Conclui-se que o lema “que” é o mais frequente.

1.4 Lugares

Por fim, para esta obra, foi pertinente analisar os nomes de lugares que surgem na obra, bem como calcular a sua frequência. Assim, foi criado o seguinte programa:

```
1 import spacy
2 import os
3 import csv
4
5 with open('a_mulher_fatal1spl.txt', 'r', encoding='UTF-8') as file:
6     text = file.read()
7
8 nlp = spacy.load('pt_core_news_sm')
9 doc = nlp(text)
10
11 locations = []
12
13 for ent in doc.ents:
14     if ent.label_ == "LOC":
15         locations.append(ent.text)
16
17 from collections import Counter
18
19 locations_counts = Counter(locations)
20
21 top30_locations = locations_counts.most_common(30)
22
23 print(top30_locations)
24
25 with open('LOCALIDADESa_mulher_fatal.csv', 'w', newline='') as file:
26     writer = csv.writer(file)
27     writer.writerow(['Localidade', 'Contagem']) # Adiciona o cabeçalho das colunas
28
29     for location, count in top30_locations:
30         writer.writerow([location, count])
31
```

Depois de carregar o documento de texto com a obra, em formato de *one sentence per line*, e o armazenar numa variável, a biblioteca *SpaCy* é carregada com um modelo de processamento de texto em português. O texto é analisado usando o modelo carregado, e o código procura todas as entidades que representam localidades. Caso uma entidade seja identificada como uma localidade, ela é adicionada a uma lista. Em seguida, é feita uma contagem das localidades presentes na lista usando a classe *Counter* da biblioteca *Python*. Esta classe cria um dicionário onde as chaves são as localidades e os valores são as contagens de ocorrência. O programa seleciona as 30 localidades mais comuns e salva com as respectivas contagens num arquivo CSV, onde cada linha contém o nome da localidade e sua contagem de ocorrências.

Assim:


1	Localidade	Contagem						
2	Lisboa	51						
3	Virgínia	21						
4	Porto	18						
5	Laura	11						
6	Esteia	11						
7	Sei	9						
8	Portugal	8						
9	Tenho	8						
10	Olha	7						
11	Paris	7						
12	Brasil	7						
13	França	6						
14	Perpétua	6						
15	Vamos	6						
16	Vou	5						
17	Júlia	5						
18	Queres	5						
19	Cassilda	5						
20	Céu	4						
21	em Portugal	4						
22	Estás	4						
23	Coimbra	4						
24	Providência	4						
25	Carlos	4						
26	Minha	4						
27	Viseu	4						
28	Cassilda Arcourt	4						
29	Filomena	4						
30	Colégio da Form	3						
31	Queira	3						
32								
33								

Mais uma vez, foi feita uma limpeza manual dos dados. Tem-se como resultado:

1	Localidade	Contagem						
2	Lisboa	51						
3	Porto	21						
4	Portugal	12						
5	Paris	7						
6	Brasil	7						
7	França	6						
8	Coimbra	4						
9	Viseu	4						
10								
11								

Como proposta de visualização, foi criado o gráfico seguinte:

LUGARES



Conclui-se que Lisboa é o lugar mais mencionado.

2. Amor de Salvação

Para esta obra, foi analisado e extraídos os verbos, as localidades, as palavras-chave e feita uma análise de sentimento por cada capítulo do livro. O documento de texto que contem a obra, foi utilizado sempre em formato de *one sentence per line*.

2.1 Verbos

Para a obra Amor de Salvação, foi relevante extrair um top dos 20 verbos que surgem com mais frequência na obra. Então, foi criado o seguinte programa:

```
2 import os
3 import csv
4 from collections import Counter
5
6 with open('amor_de_salvacao1spl.txt', 'r', encoding='UTF-8') as file:
7     text = file.read()
8
9 nlp = spacy.load('pt_core_news_sm')
10 doc = nlp(text)
11
12 dicionario = dict()
13
14 for token in doc:
15     if token.pos_ == "VERB":
16         if token.lemma_ in dicionario.keys():
17             dicionario[token.lemma_] += 1
18         else:
19             dicionario[token.lemma_] = 1
20
21 verb_counts = Counter(dicionario)
22 top20_verbs = verb_counts.most_common(20)
23
24 print(top20_verbs)
25
26 with open('VERBOSamor_de_salvacao.csv', 'w', newline='') as file:
27     writer = csv.writer(file)
28     writer.writerow(['Verbo', 'Contagem']) # Adiciona o cabeçalho das colunas
29
30     for verb, count in top20_verbs:
31         writer.writerow([verb, count])
32
```


O código realiza uma análise de verbos usando a biblioteca *Spacy*, com o modelo de linguagem em português. Ele conta a frequência de ocorrência de cada verbo no texto e imprime os 20 verbos mais frequentes. Além disso, os resultados são salvos em um arquivo CSV com duas colunas: "Verbo" e "Contagem". Em seguida, um dicionário vazio é criado para armazenar os verbos e as suas contagens.

O *loop* percorre cada *token* no documento e verifica se esse *token* é um verbo. Se for, o lema do verbo é adicionado ao dicionário, aumentando sua contagem de ocorrência. Se o verbo já estiver presente no dicionário, sua contagem é atualizada. Caso contrário, o verbo é adicionado ao dicionário com uma contagem inicial de 1.

A biblioteca `'Counter'` é usada para contar a frequência dos verbos no dicionário. Os 20 verbos mais comuns são selecionados usando o método `'most_common(20)'` e armazenados na lista `'top20_verbs'`. A lista extraída é a seguinte:

1	Verbo	Contagem						
2	dizer	235						
3	ter	162						
4	ver	134						
5	saber	123						
6	dar	114						
7	poder	103						
8	fazer	96						
9	haver	95						
10	ir	88						
11	ser	78						
12	querer	75						
13	vir	62						
14	pedir	56						
15	sair	52						
16	responder	50						
17	amar	44						
18	deixar	42						
19	ouvir	38						
20	chorar	38						
21	falar	36						

Neste caso, não efetuei qualquer tipo de limpeza uma vez que os dados se revelaram bastante precisos. Então, como proposta de visualização creio que um gráfico de barras acabou por ser a melhor opção:



Como era de esperar, os verbos mais comuns são os verbos copulativos. Porém, é de realçar o surgimento dos verbos amar e chorar no top 20 dos verbos que mais surgem na obra.

2.2 Análise de Sentimento

Para fazer a análise de sentimento de cada capítulo, criei o seguinte programa *Python*, que utiliza a biblioteca *NLTK* (*Natural Language Toolkit*) para realizar uma análise de sentimentos num dado texto. Ele utiliza o módulo '*SentimentIntensityAnalyzer*' do *NLTK*, que é responsável por atribuir pontuações de sentimento a diferentes partes do texto.

```

1 import nltk
2 from nltk.sentiment import SentimentIntensityAnalyzer
3
4 nltk.download('vader_lexicon')
5
6 sia = SentimentIntensityAnalyzer()
7
8 caminho_arquivo = "amor_de_salvacao1spl.txt"
9
10 with open(caminho_arquivo, 'r', encoding='utf-8') as arquivo:
11     texto = arquivo.read()
12
13 capitulos = texto.split('# Capítulo')
14
15 for i, capitulo in enumerate(capitulos[1:]):
16     sentiment = sia.polarity_scores(capitulo)
17     print(f"Sentimento do Capítulo {i+1}: {sentiment}")
18

```

Primeiro, o código importa as bibliotecas necessárias e faz o download do léxico *Vader do NLTK*, que é usado para análise de sentimentos. Em seguida, é criada uma instância do `'SentimentIntensityAnalyzer'`.

Depois, o código lê o arquivo *txt* da obra *A mulher fatal* no formato de *one sentence per line* e armazena-o numa variável. O texto é dividido em capítulos usando um marcador específico (no caso, foi colocada um # em cada capítulo no documento de texto). Através de um *loop*, cada capítulo é analisado usando o `'SentimentIntensityAnalyzer'`, que retorna uma pontuação de sentimento para aquele capítulo.

Em resumo, o código realiza a análise de sentimentos no texto, dividindo-o em capítulos e calculando a pontuação de sentimento para cada um deles. Os resultados no terminal são:

```
Sentimento do Capítulo 1: {'neg': 0.016, 'neu': 0.972, 'pos': 0.012, 'compound': -0.5897}
Sentimento do Capítulo 2: {'neg': 0.016, 'neu': 0.97, 'pos': 0.013, 'compound': -0.4035}
Sentimento do Capítulo 3: {'neg': 0.02, 'neu': 0.98, 'pos': 0.0, 'compound': -0.9157}
Sentimento do Capítulo 4: {'neg': 0.02, 'neu': 0.957, 'pos': 0.023, 'compound': 0.8377}
Sentimento do Capítulo 5: {'neg': 0.018, 'neu': 0.972, 'pos': 0.01, 'compound': -0.86}
Sentimento do Capítulo 6: {'neg': 0.017, 'neu': 0.972, 'pos': 0.011, 'compound': -0.7067}
Sentimento do Capítulo 7: {'neg': 0.023, 'neu': 0.961, 'pos': 0.016, 'compound': -0.8035}
Sentimento do Capítulo 8: {'neg': 0.006, 'neu': 0.987, 'pos': 0.007, 'compound': 0.7374}
Sentimento do Capítulo 20: {'neg': 0.022, 'neu': 0.971, 'pos': 0.006, 'compound': -0.972}
Sentimento do Capítulo 21: {'neg': 0.02, 'neu': 0.972, 'pos': 0.008, 'compound': -0.78}
Sentimento do Capítulo 22: {'neg': 0.022, 'neu': 0.972, 'pos': 0.006, 'compound': -0.954}
Sentimento do Capítulo 23: {'neg': 0.012, 'neu': 0.971, 'pos': 0.017, 'compound': 0.9655}
Sentimento do Capítulo 10: {'neg': 0.014, 'neu': 0.973, 'pos': 0.012, 'compound': 0.814}
Sentimento do Capítulo 11: {'neg': 0.015, 'neu': 0.972, 'pos': 0.013, 'compound': 0.8492}
Sentimento do Capítulo 12: {'neg': 0.038, 'neu': 0.957, 'pos': 0.005, 'compound': -0.9686}
Sentimento do Capítulo 13: {'neg': 0.012, 'neu': 0.984, 'pos': 0.004, 'compound': -0.9453}
Sentimento do Capítulo 14: {'neg': 0.014, 'neu': 0.982, 'pos': 0.004, 'compound': -0.9547}
Sentimento do Capítulo 15: {'neg': 0.022, 'neu': 0.971, 'pos': 0.006, 'compound': -0.9839}
Sentimento do Capítulo 16: {'neg': 0.027, 'neu': 0.965, 'pos': 0.009, 'compound': -0.9796}
Sentimento do Capítulo 17: {'neg': 0.017, 'neu': 0.98, 'pos': 0.004, 'compound': -0.9706}
Sentimento do Capítulo 18: {'neg': 0.025, 'neu': 0.975, 'pos': 0.0, 'compound': -0.982}
Sentimento do Capítulo 19: {'neg': 0.011, 'neu': 0.972, 'pos': 0.017, 'compound': 0.9533}
Sentimento do Capítulo 20: {'neg': 0.022, 'neu': 0.971, 'pos': 0.006, 'compound': -0.972}
Sentimento do Capítulo 21: {'neg': 0.02, 'neu': 0.972, 'pos': 0.008, 'compound': -0.78}
Sentimento do Capítulo 22: {'neg': 0.022, 'neu': 0.972, 'pos': 0.006, 'compound': -0.954}
Sentimento do Capítulo 23: {'neg': 0.012, 'neu': 0.971, 'pos': 0.017, 'compound': 0.9655}
PS C:\Users\ines2\OneDrive\Ambiente de Trabalho\avd2023\trabalho final avd>
```

Para construir uma proposta de visualização para a análise de sentimento do livro *Amor de Salvação*, utilizou-se o mesmo método que se tinha utilizado no livro anterior. Então, o programa foi o seguinte:

```

import matplotlib.pyplot as plt

pontuacoes = [
    {'neg': 0.016, 'neu': 0.972, 'pos': 0.012, 'compound': -0.5897},
    {'neg': 0.016, 'neu': 0.97, 'pos': 0.013, 'compound': -0.4035},
    {'neg': 0.02, 'neu': 0.98, 'pos': 0.0, 'compound': -0.9157},
    {'neg': 0.02, 'neu': 0.957, 'pos': 0.023, 'compound': 0.8377},
    {'neg': 0.018, 'neu': 0.972, 'pos': 0.01, 'compound': -0.86},
    {'neg': 0.017, 'neu': 0.972, 'pos': 0.011, 'compound': -0.7067},
    {'neg': 0.023, 'neu': 0.961, 'pos': 0.016, 'compound': -0.8035},
    {'neg': 0.006, 'neu': 0.987, 'pos': 0.007, 'compound': 0.7374},
    {'neg': 0.015, 'neu': 0.976, 'pos': 0.009, 'compound': -0.6935},
    {'neg': 0.014, 'neu': 0.973, 'pos': 0.012, 'compound': 0.814},
    {'neg': 0.015, 'neu': 0.972, 'pos': 0.013, 'compound': 0.8492},
    {'neg': 0.038, 'neu': 0.957, 'pos': 0.005, 'compound': -0.9686},
    {'neg': 0.012, 'neu': 0.984, 'pos': 0.004, 'compound': -0.9453},
    {'neg': 0.014, 'neu': 0.982, 'pos': 0.004, 'compound': -0.9547},
    {'neg': 0.022, 'neu': 0.971, 'pos': 0.006, 'compound': -0.9839},
    {'neg': 0.027, 'neu': 0.965, 'pos': 0.009, 'compound': -0.9796},
    {'neg': 0.017, 'neu': 0.98, 'pos': 0.004, 'compound': -0.9706},
    {'neg': 0.025, 'neu': 0.975, 'pos': 0.0, 'compound': -0.982},
    {'neg': 0.011, 'neu': 0.972, 'pos': 0.017, 'compound': 0.9533},
    {'neg': 0.022, 'neu': 0.971, 'pos': 0.006, 'compound': -0.972},
    {'neg': 0.02, 'neu': 0.972, 'pos': 0.008, 'compound': -0.78},
    {'neg': 0.022, 'neu': 0.972, 'pos': 0.006, 'compound': -0.954},
    {'neg': 0.012, 'neu': 0.971, 'pos': 0.017, 'compound': 0.9655}
]

valores_compound = [sentimento['compound'] for sentimento in pontuacoes]

rotulos = [f"Capítulo {i+1}" for i in range(len(pontuacoes))]

24     {'neg': 0.02, 'neu': 0.972, 'pos': 0.008, 'compound': -0.78},
25     {'neg': 0.022, 'neu': 0.972, 'pos': 0.006, 'compound': -0.954},
26     {'neg': 0.012, 'neu': 0.971, 'pos': 0.017, 'compound': 0.9655}
27 ]
28
29 valores_compound = [sentimento['compound'] for sentimento in pontuacoes]
30
31 rotulos = [f"Capítulo {i+1}" for i in range(len(pontuacoes))]
32
33 plt.figure(figsize=(10, 6))
34 plt.bar(rotulos, valores_compound)
35 plt.xlabel('Capítulo')
36 plt.ylabel('Sentimento (compound)')
37 plt.title('Análise de Sentimento por Capítulo')
38 plt.xticks(rotation=45)
39 plt.show()
40


```

O código em questão utiliza a biblioteca Matplotlib em conjunto com os resultados da análise de sentimento por capítulos para criar um gráfico de barras. O objetivo é visualizar a variação do sentimento ao longo dos capítulos de uma obra. Inicialmente, os resultados da análise de sentimento por capítulo são armazenados numa lista chamada `pontuacoes`. Cada elemento dessa lista é um dicionário que contém as pontuações de negatividade (`neg`), neutralidade (`neu`), positividade (`pos`) e a pontuação geral do sentimento (`compound`) para um capítulo específico.

O próximo passo consiste em extrair os valores do `compound` de cada dicionário da lista `pontuacoes`. Esses valores são armazenados numa lista separada chamada

`valores_compound`. Esta lista representa a medida agregada do sentimento para cada capítulo. A lista `rotulos` é criada para armazenar os rótulos dos capítulos. Cada rótulo é definido como "Capítulo X", onde X é o número do capítulo correspondente. Com todos os dados necessários preparados, o código utiliza a biblioteca Matplotlib para criar o gráfico de barras. É criada uma figura com um tamanho específico utilizando a função `plt.figure(figsize=(10, 6))`. Em seguida, a função `plt.bar()` é utilizada para criar as barras do gráfico. Os rótulos dos capítulos são exibidos no eixo x e os valores do compound são representados no eixo y. Algumas funções do Matplotlib, como `plt.xlabel()`, `plt.ylabel()`, `plt.title()` e `plt.xticks(rotation=45)`, são utilizadas para adicionar rótulos aos eixos e ao gráfico em geral, além de fazer uma rotação de 45 graus nos rótulos dos capítulos para facilitar a leitura. Por fim, o gráfico é exibido na tela utilizando a função `plt.show()`.

Assim, o gráfico:



Para concluir, é maior a quantidade de capítulos com sentimento negativo do que positivo, embora o final seja positivo.

2.3 Palavras-Chave

Para obra Amor de Salvação, foi relevante fazer uma extração de palavras-chave da obra. Assim, foi criado o seguinte programa em python:

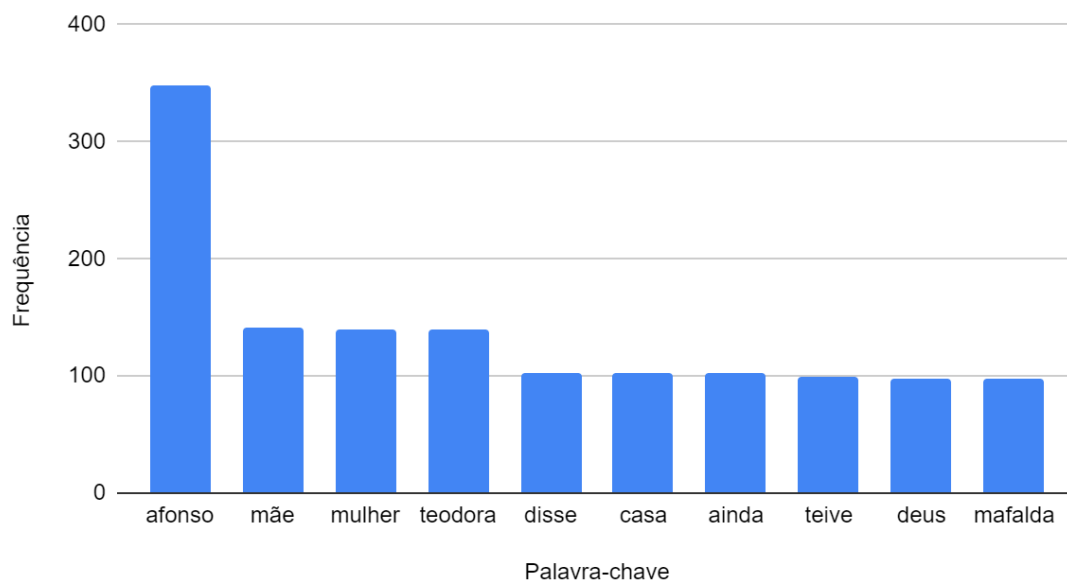
```
1 import csv
2 from collections import Counter
3 import string
4 import nltk
5 from nltk.corpus import stopwords
6
7 nltk.download('stopwords')
8
9 stop_words = set(stopwords.words('portuguese'))
10
11 def extrair_palavras_chave(texto):
12     texto = texto.translate(str.maketrans('', '', string.punctuation)).lower()
13     palavras = texto.split()
14     palavras = [palavra for palavra in palavras if palavra not in stop_words]
15     contagem_palavras = Counter(palavras)
16     return contagem_palavras
17
18 with open('amor_de_salvacao1spl.txt', 'r', encoding='utf-8') as arquivo:
19     texto = arquivo.read()
20
21 palavras_chave = extrair_palavras_chave(texto)
22 e
23 top_palavras_chave = palavras_chave.most_common(10)
24
25 nome_arquivo_csv = 'palavras_chave.csv'
26
27 with open(nome_arquivo_csv, 'w', newline='', encoding='utf-8') as arquivo_csv:
28     writer = csv.writer(arquivo_csv)
29     writer.writerow(['Palavra-chave', 'Frequência']) # Cabeçalho das colunas
30
31     for palavra, frequencia in top_palavras_chave:
32         writer.writerow([palavra, frequencia])
```

Primeiro, são importadas as bibliotecas necessárias para o processamento de texto, contagem de palavras e manipulação de arquivos *csv*. Depois, faz-se uma baixa das *stop-words*, em português, através da NLTK. A função *extrair_palavras_chave* recebe o texto como entrada, onde dentro da mesma, será removida a pontuação de texto e convertidas as maiúsculas para minúsculas. Depois de o texto dividido e desprovido de *stop-words*, conta-se a frequência de ocorrência através da biblioteca Counter. Depois de extraídas as 10 palavras que mais surgem no texto, cria-se um documento *csv* com os resultados, sendo eles:


1	Palavra-chave	Frequência					
2	afonso	348					
3	mãe	142					
4	mulher	140					
5	teodora	139					
6	disse	103					
7	casa	102					
8	ainda	102					
9	teve	99					
10	deus	97					
11	mafalda	97					
12							
13							

Mais uma vez, não foi necessário recorrer a limpeza dos dados. Como proposta de visualização, foi criado um gráfico de barras e um gráfico circular.

Frequência de palavras-chave da obra Amor de Salvação



Frequência



O nome Afonso é, com destaque, a palavra mais utilizada.

2.4 Lugares

Por fim, para esta obra, foi pertinente analisar os nomes de lugares que surgem na obra, bem como calcular a sua frequência. Assim, foi utilizado o mesmo programa que em 1.4:

```
1 import spacy
2 import os
3 import csv
4
5 with open('amor_de_salvacao1spl.txt', 'r', encoding='UTF-8') as file:
6     text = file.read()
7
8 nlp = spacy.load('pt_core_news_sm')
9 doc = nlp(text)
10
11 locations = []
12
13 for ent in doc.ents:
14     if ent.label_ == "LOC":
15         locations.append(ent.text)
16
17 from collections import Counter
18
19 locations_counts = Counter(locations)
20
21 top30_locations = locations_counts.most_common(30)
22
23 print(top30_locations)
24
25 with open('LUGARESamor_de_salvacao.csv', 'w', newline='') as file:
26     writer = csv.writer(file)
27     writer.writerow(['Localidade', 'Contagem'])
28     for location, count in top30_locations:
29         writer.writerow([location, count])
```

Depois de carregar o documento de texto com a obra Amor de Salvação, em formato de one sentence per line, e o armazenar numa variável, a biblioteca SpaCy é carregada com um modelo de processamento de texto em português. O texto é analisado usando o modelo carregado, e o código procura todas as entidades que representam localidades. Caso uma entidade seja identificada como uma localidade, ela é adicionada a uma lista. Em seguida, é feita uma contagem das localidades presentes na lista usando a classe 'Counter' da biblioteca Python. Esta classe cria um dicionário onde as chaves são as localidades e os valores são as contagens de ocorrência. O programa seleciona as 30 localidades mais comuns e salva-com as respetivas contagens num arquivo CSV, onde cada linha contém o nome da localidade e sua contagem de ocorrências.

O documento csv, então:


1	Localidade	Contagem							
2	Palmira	33							
3	Lisboa	31							
4	Paris	17							
5	Céu	16							
6	Ruivães	13							
7	Eleutério	13							
8	Minho	10							
9	Coimbra	10							
10	Tranqueira	9							
11	Braga	8							
12	Portugal	7							
13	Terra	7							
14	França	6							
15	Fervença	6							
16	Eleutério Romão	6							
17	Vamos	6							
18	Estás	5							
19	Minha	5							
20	Sintra	5							
21	Entrei	4							
22	Porto	4							
23	Queres	4							
24	Barcelos	4							
25	Guimarães	3							
26	Campo Grande	3							
27	Afonso de Teive	3							
28	Criador	3							
29	Ursulinas	3							
30	Dizia	3							
31	Romão	3							
--									

Procedeu-se a uma limpeza manual dos dados:

1	Lugar	Contagem						
2	Lisboa	31						
3	Paris	17						
4	Ruivães	13						
5	Minho	10						
6	Coimbra	10						
7	Tranqueira	9						
8	Braga	8						
9	Portugal	7						
10	França	6						
11	Fervença	6						
12	Sintra	5						
13	Porto	4						
14	Barcelos	4						
15	Guimarães	3						
16	Campo Grande	3						
17								

Criou-se a seguinte proposta de visualização:

Contagem em comparação com Lugar



Lisboa é então o lugar mais mencionado na obra.

3. O Romance de Um Homem Rico

Para esta obra, foi analisado e extraídos os lemas, as entidades, os adjetivos e feita uma análise de sentimento por cada capítulo do livro. O documento de texto que contem a obra, foi utilizado sempre em formato de *one sentence per line*.

3.1 Entidades

Para extrair as entidades da obra *O Romance Dum Homem Rico*, utilizei o seguinte programa Python, utilizando a biblioteca spaCy:


Este programa extrairá um Top 30 personagens, juntamente com o número de vezes que cada uma surge na obra. O programa cria um documento csv com os resultados:

Depois de uma análise manual dos dados, obteve-se:


1	Personagem	Contagem					
2	Leonor	193					
3	Maria da Glória	141					
4	Manuel Teixeira	52					
5	João de Matos	39					
6	Sebastião de Bri	29					
7	Miguel de Sotto-	37					
8	Álvaro Teixeira	31					
9	Soror Joana	7					
10							
11							

Como proposta de visualização, neste caso, foram criados dois gráficos. Um circular e outro de barras.

Contagem



Contagem em comparação com Personagem



Leonor é, portanto, a personagem mais mencionada no livro.

3.2 Adjetivos

Em segundo lugar, para esta obra, foi analisado o top 20 adjetivos mais utilizados, através do seguinte código python:

```
1 import spacy
2 import csv
3 from collections import Counter
4
5 nlp = spacy.load('pt_core_news_sm')
6
7 with open('o_romance_dum_homem_rico1spl.txt', 'r', encoding='utf-8') as file:
8     text = file.read()
9
10 doc = nlp(text)
11
12 adjectives = Counter()
13
14 for token in doc:
15     if token.pos_ == 'ADJ':
16         adjectives[token.lemma_] += 1
17
18 top20_adjectives = adjectives.most_common(20)
19
20 with open('adjetivos_omromancedumhomemrico.csv', 'w', newline='') as file:
21     writer = csv.writer(file)
22     writer.writerow(['Adjetivo', 'Frequência'])
23     writer.writerows(top20_adjectives)
24
```

O programa utiliza a biblioteca *Spacy* para extrair os 20 adjetivos mais frequentes da obra em formato TXT. Primeiro, o texto é lido a partir de um arquivo TXT e processado

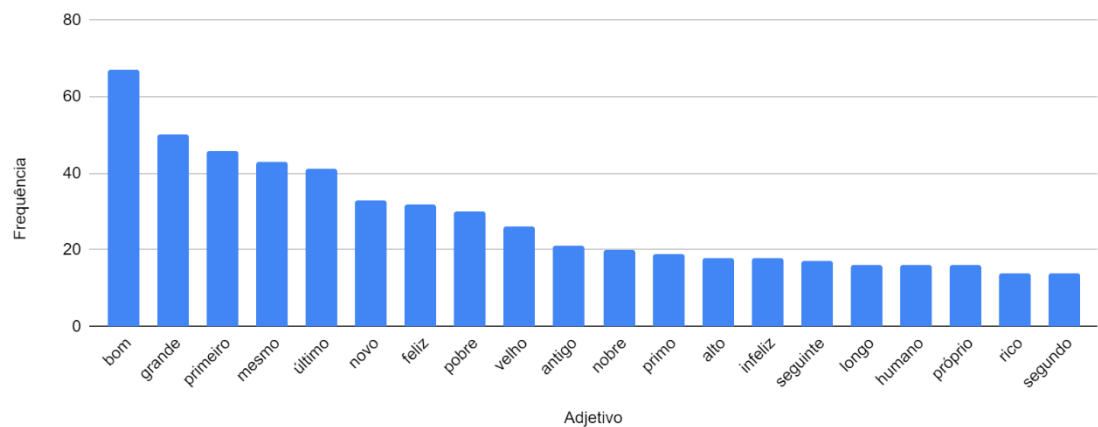
pelo *Spacy*. Em seguida, os adjetivos são identificados e contados. Os 20 adjetivos mais comuns são armazenados num arquivo *CSV*.

Os resultados obtidos foram:

1	Adjetivo	Frequência						
2	bom	67						
3	grande	50						
4	primeiro	46						
5	mesmo	43						
6	último	41						
7	novo	33						
8	feliz	32						
9	pobre	30						
10	velho	26						
11	antigo	21						
12	nobre	20						
13	primo	19						
14	alto	18						
15	infeliz	18						
16	seguinte	17						
17	longo	16						
18	humano	16						
19	próprio	16						
20	rico	14						
21	segundo	14						

Uma vez que não foi necessária qualquer tipo de limpeza aos dados, cria-se a seguinte proposta de visualização:

Frequência em comparação com Adjetivo



Conclui-se que *bom* é o adjetivo mais comum na obra.

3.3 Lemas

Para extrair um top 50 lemas da obra O Romance Dum Homem Rico, foi criado o seguinte programa:


```
1 import nltk
2 from nltk import FreqDist
3 from nltk.corpus import stopwords
4 from nltk.stem import WordNetLemmatizer
5 import csv
6
7 nltk.download('punkt')
8 nltk.download('stopwords')
9 nltk.download('wordnet')
10
11 def extract_lemmas(text):
12     lemmatizer = WordNetLemmatizer()
13     stop_words = set(stopwords.words('english'))
14
15     tokens = nltk.word_tokenize(text)
16     lemmas = [lemmatizer.lemmatize(token.lower()) for token in tokens if token.isalnum() and token.lower() not in stop_words]
17
18     return lemmas
19
20 def save_lemmas_to_csv(lemmas, output_file):
21     fdist = FreqDist(lemmas)
22     top_lemmas = fdist.most_common(50)
23
24     with open(output_file, 'w', newline='') as csvfile:
25         writer = csv.writer(csvfile)
26         writer.writerow(['Lemma', 'Frequency'])
27         for lemma, freq in top_lemmas:
28             writer.writerow([lemma, freq])
29
30 input_file = 'o_romance_dum_homem_rico1spl.txt'
31
32 output_file = 'TOP50oromancedumhomemrico.csv'
33
34 with open(input_file, 'r') as file:
35     text = file.read()
36
37 lemmas = extract_lemmas(text)
38
39 save_lemmas_to_csv(lemmas, output_file)
```

O programa utiliza o NLTK para extrair os lemas da obra, carregada em formato de texto, bem como calcula a frequência que cada um aparece no texto. Assim, os 50 lemas mais frequentes são guardados num arquivo novo em formato csv. Tem-se:

O programa utiliza o NLTK para extrair os lemas da obra, carregada em formato de texto, bem como calcula a frequência que cada um aparece no texto. Assim, os 50 lemas mais frequentes são guardados num arquivo novo em formato csv. Tem-se:

[illegible]

Uma vez que todos os resultados são lemas, não se realizou qualquer tipo de limpeza. Como proposta de visualização:



Como esperado, as preposições e conjunções são os lemas mais presentes no texto.

3.4 Análise de Sentimento

Para fazer a análise de sentimento de cada capítulo desta obra, foi utilizado o seguinte programa *Python*, que utiliza a biblioteca *NLTK* (*Natural Language Toolkit*) para realizar uma análise de sentimentos num dado texto. Ele utiliza o módulo `'SentimentIntensityAnalyzer'` do *NLTK*, que é responsável por atribuir pontuações de sentimento a diferentes partes do texto.

```
1 import nltk
2 from nltk.sentiment import SentimentIntensityAnalyzer
3
4 nltk.download('vader_lexicon')
5
6 sia = SentimentIntensityAnalyzer()
7
8 caminho_arquivo = "o_romance_dum_homem_rico1spl.txt"
9
10 with open(caminho_arquivo, 'r', encoding='utf-8') as arquivo:
11     texto = arquivo.read()
12
13 capitulos = texto.split('# Capítulo')
14
15 for i, capitulo in enumerate(capitulos[1:]):
16     sentiment = sia.polarity_scores(capitulo)
17     print(f"Sentimento do Capítulo {i+1}: {sentiment}")
18
```

Primeiro, o código importa as bibliotecas necessárias e faz o download do léxico Vader do NLTK, que é usado para análise de sentimentos. Em seguida, é criada uma instância do `'SentimentIntensityAnalyzer'`.

Depois, o código lê o arquivo txt da obra *A mulher fatal* no formato de one sentence per line e armazena-o numa variável. O texto é dividido em capítulos usando um marcador específico (no caso, foi colocada um # em cada capítulo no documento de texto). Através de um loop, cada capítulo é analisado usando o `'SentimentIntensityAnalyzer'`, que retorna uma pontuação de sentimento para aquele capítulo.

Em resumo, o código realiza a análise de sentimentos no texto, dividindo-o em capítulos e calculando a pontuação de sentimento para cada um deles. Os resultados no terminal são:

```

Sentimento do Capítulo 1: {'neg': 0.015, 'neu': 0.972, 'pos': 0.013, 'compound': 0.8667}
Sentimento do Capítulo 2: {'neg': 0.017, 'neu': 0.971, 'pos': 0.012, 'compound': -0.5759}
Sentimento do Capítulo 3: {'neg': 0.024, 'neu': 0.949, 'pos': 0.027, 'compound': 0.9519}
Sentimento do Capítulo 4: {'neg': 0.015, 'neu': 0.976, 'pos': 0.009, 'compound': -0.7862}
Sentimento do Capítulo 5: {'neg': 0.009, 'neu': 0.979, 'pos': 0.012, 'compound': 0.8634}
Sentimento do Capítulo 6: {'neg': 0.011, 'neu': 0.982, 'pos': 0.007, 'compound': -0.6628}
Sentimento do Capítulo 7: {'neg': 0.009, 'neu': 0.973, 'pos': 0.017, 'compound': 0.9619}
Sentimento do Capítulo 8: {'neg': 0.015, 'neu': 0.974, 'pos': 0.011, 'compound': -0.5897}
Sentimento do Capítulo 9: {'neg': 0.016, 'neu': 0.975, 'pos': 0.009, 'compound': -0.703}
Sentimento do Capítulo 10: {'neg': 0.018, 'neu': 0.973, 'pos': 0.009, 'compound': -0.9264}
Sentimento do Capítulo 11: {'neg': 0.026, 'neu': 0.957, 'pos': 0.017, 'compound': -0.5897}
Sentimento do Capítulo 12: {'neg': 0.015, 'neu': 0.968, 'pos': 0.017, 'compound': 0.8729}
Sentimento do Capítulo 13: {'neg': 0.019, 'neu': 0.969, 'pos': 0.012, 'compound': -0.7736}
Sentimento do Capítulo 14: {'neg': 0.017, 'neu': 0.968, 'pos': 0.015, 'compound': 0.8565}
Sentimento do Capítulo 15: {'neg': 0.007, 'neu': 0.99, 'pos': 0.002, 'compound': -0.7862}
Sentimento do Capítulo 16: {'neg': 0.016, 'neu': 0.973, 'pos': 0.012, 'compound': -0.5897}
Sentimento do Capítulo 17: {'neg': 0.013, 'neu': 0.96, 'pos': 0.028, 'compound': 0.9919}
Sentimento do Capítulo 18: {'neg': 0.019, 'neu': 0.969, 'pos': 0.012, 'compound': -0.8729}
Sentimento do Capítulo 19: {'neg': 0.022, 'neu': 0.965, 'pos': 0.013, 'compound': -0.814}
Sentimento do Capítulo 20: {'neg': 0.018, 'neu': 0.969, 'pos': 0.013, 'compound': -0.5897}
PS C:\Users\ines2\OneDrive\Ambiente de Trabalho\avd2023\trabalho final avd>

```

Para uma análise mais profunda, tem-se:

- Capítulo 1: Sentimento positivo moderado (compound: 0.8667)
- Capítulo 2: Sentimento negativo moderado (compound: -0.5759)
- Capítulo 3: Sentimento positivo forte (compound: 0.9519)
- Capítulo 4: Sentimento negativo moderado (compound: -0.7862)
- Capítulo 5: Sentimento positivo moderado (compound: 0.8634)
- Capítulo 6: Sentimento negativo moderado (compound: -0.6628)
- Capítulo 7: Sentimento positivo forte (compound: 0.9619)
- Capítulo 8: Sentimento negativo moderado (compound: -0.5897)
- Capítulo 9: Sentimento negativo moderado (compound: -0.703)
- Capítulo 10: Sentimento negativo forte (compound: -0.9264)
- Capítulo 11: Sentimento negativo moderado (compound: -0.5897)
- Capítulo 12: Sentimento positivo moderado (compound: 0.8729)
- Capítulo 13: Sentimento negativo moderado (compound: -0.7736)
- Capítulo 14: Sentimento positivo moderado (compound: 0.8565)
- Capítulo 15: Sentimento negativo moderado (compound: -0.7862)
- Capítulo 16: Sentimento negativo moderado (compound: -0.5897)
- Capítulo 17: Sentimento positivo forte (compound: 0.9919)
- Capítulo 18: Sentimento negativo moderado (compound: -0.8729)
- Capítulo 19: Sentimento negativo moderado (compound: -0.814)
- Capítulo 20: Sentimento negativo moderado (compound: -0.5897)


Essa análise é baseada no valor do atributo '*compound*' de cada capítulo. O valor composto (*compound*) varia de -1 a 1, representando um sentimento negativo forte a um sentimento positivo forte, respectivamente. Valores próximos de 0 indicam sentimentos neutros.

Pode observar-se que a maioria dos capítulos apresenta sentimentos moderados, sendo alguns positivos e outros negativos. Alguns capítulos específicos destacam-se com sentimentos positivos fortes (capítulo 3, capítulo 7 e capítulo 17), enquanto outros têm sentimentos negativos mais intensos (capítulo 10 e capítulo 18).

Em seguida, para criar uma proposta de visualização, foi feito um programa para criar um gráfico de barras:

```
1 import matplotlib.pyplot as plt
2
3 pontuacoes = [
4     {'neg': 0.015, 'neu': 0.972, 'pos': 0.013, 'compound': 0.8667},
5     {'neg': 0.017, 'neu': 0.971, 'pos': 0.012, 'compound': -0.5759},
6     {'neg': 0.024, 'neu': 0.949, 'pos': 0.027, 'compound': 0.9519},
7     {'neg': 0.015, 'neu': 0.976, 'pos': 0.009, 'compound': -0.7862},
8     {'neg': 0.009, 'neu': 0.979, 'pos': 0.012, 'compound': 0.8634},
9     {'neg': 0.011, 'neu': 0.982, 'pos': 0.007, 'compound': -0.6628},
10    {'neg': 0.009, 'neu': 0.973, 'pos': 0.017, 'compound': 0.9619},
11    {'neg': 0.015, 'neu': 0.974, 'pos': 0.011, 'compound': -0.5897},
12    {'neg': 0.016, 'neu': 0.975, 'pos': 0.009, 'compound': -0.703},
13    {'neg': 0.018, 'neu': 0.973, 'pos': 0.009, 'compound': -0.9264},
14    {'neg': 0.026, 'neu': 0.957, 'pos': 0.017, 'compound': -0.5897},
15    {'neg': 0.015, 'neu': 0.968, 'pos': 0.017, 'compound': 0.8729},
16    {'neg': 0.019, 'neu': 0.969, 'pos': 0.012, 'compound': -0.7736},
17    {'neg': 0.017, 'neu': 0.968, 'pos': 0.015, 'compound': 0.8565},
18    {'neg': 0.007, 'neu': 0.99, 'pos': 0.002, 'compound': -0.7862},
19    {'neg': 0.016, 'neu': 0.973, 'pos': 0.012, 'compound': -0.5897},
20    {'neg': 0.013, 'neu': 0.96, 'pos': 0.028, 'compound': 0.9919},
21    {'neg': 0.019, 'neu': 0.969, 'pos': 0.012, 'compound': -0.8729},
22    {'neg': 0.022, 'neu': 0.965, 'pos': 0.013, 'compound': -0.814},
23    {'neg': 0.018, 'neu': 0.969, 'pos': 0.013, 'compound': -0.5897}
24 ]
25
26 valores_compound = [sentimento['compound'] for sentimento in pontuacoes]
27
28 rotulos = [f"Capítulo {i+1}" for i in range(len(pontuacoes))]
29
30 plt.figure(figsize=(10, 6))
31 plt.bar(rotulos, valores_compound)
32 plt.xlabel('Capítulo')
33 plt.ylabel('Sentimento (compound)')
34 plt.title('Análise de Sentimento por Capítulo')
35 plt.xticks(rotation=45)
36 plt.show()
```

O resultado:



Conclui-se que a quantidade de capítulos negativos se sobrepõe à de capítulos positivos.

4. Onde está a Felicidade?

Para esta obra, foram analisados e extraídos os verbos do texto, as palavras-chave, os advérbios e foi feita uma análise de sentimento por cada capítulo do livro. O documento de texto que contém a obra, foi utilizado sempre em formato de *one sentence per line*.

4.1 Palavras-Chave

Para obra “Onde Está a Felicidade?”, foi relevante fazer uma extração de palavras-chave da obra. Assim, foi criado o seguinte programa em *python*:

```
1 import csv
2 from collections import Counter
3 import string
4 import nltk
5 from nltk.corpus import stopwords
6
7
8 nltk.download('stopwords')
9
10 stop_words = set(stopwords.words('portuguese'))
11
12 def extrair_palavras_chave(texto):
13     texto = texto.translate(str.maketrans('', '', string.punctuation)).lower()
14     palavras = texto.split()
15     palavras = [palavra for palavra in palavras if palavra not in stop_words]
16     contagem_palavras = Counter(palavras)
17     return contagem_palavras
18
19 with open('onde_esta_a_felicidade1spl.txt', 'r', encoding='utf-8') as arquivo:
20     texto = arquivo.read()
21
22 palavras_chave = extrair_palavras_chave(texto)
23
24 top_palavras_chave = palavras_chave.most_common(10)
25
26 nome_arquivo_csv = 'felicidadepalavras_chave.csv'
27
28 with open(nome_arquivo_csv, 'w', newline='', encoding='utf-8') as arquivo_csv:
29     writer = csv.writer(arquivo_csv)
30     writer.writerow(['Palavra-chave', 'Frequência']) # Cabeçalho das colunas
31
32     for palavra, frequencia in top_palavras_chave:
33         writer.writerow([palavra, frequencia])
34
35 print("As 10 principais palavras-chave foram extraídas e salvas com sucesso no arquivo", nome_arquivo_csv)
36
37
38
```

Primeiro, são importadas as bibliotecas necessárias para o processamento de texto, contagem de palavras e manipulação de arquivos csv. Depois, faz-se uma baixa das stop-words, em português, através da NLTK. A função `extrair_palavras_chave` recebe o texto como entrada, onde dentro da mesma, será removida a pontuação de texto e convertidas as maiúsculas para minúsculas. Depois de o texto dividido e desprovido de stop-words, conta-se a frequência de ocorrência através da biblioteca `Counter`. Depois de extraídas as 10 palavras que mais surgem no texto, cria-se um documento csv com os resultados, sendo eles:


1	Palavra-chave	Frequência					
2	—	2315					
3	augusta	395					
4	guilherme	269					
5	amaral	200					
6	mulher	197					
7	disse	190					
8	homem	174					
9	casa	161					
10	pois	158					
11	assim	141					
12							
13							

Depois, foi feita então uma limpeza dos dados:

1	Palavra-chave	Frequência					
2	augusta	395					
3	guilherme	269					
4	amaral	200					
5	mulher	197					
6	disse	190					
7	homem	174					
8	casa	161					
9	pois	158					
10	assim	141					
11							
12							
13							

Para proposta de visualização, tem-se:

Frequência em comparação com Palavra-chave



4.2 Advérbios

Seguidamente, a análise avançou para uma extração de um top 20 de advérbios que mais surgem na obra, bem como a frequência com que aparecem, através do seguinte programa:


```
1 import csv
2 import re
3 from collections import Counter
4
5 def extrair_adverbios(texto):
6     padrao = r'\b\w+mente\b'
7     adverbios = re.findall(padrao, texto, re.IGNORECASE)
8     return adverbios
9
10 def contar_frequencia(adverbios):
11     contagem = Counter(adverbios)
12     return contagem
13
14 def criar_csv(resultado, arquivo):
15     with open(arquivo, 'w', newline='') as csv_file:
16         writer = csv.writer(csv_file)
17         writer.writerow(['Adverbio', 'Frequencia'])
18         writer.writerows(resultado)
19     print(f'O arquivo {arquivo} foi criado com sucesso!')
20
21 with open('onde_esta_a_felicidade1.txt', 'r') as arquivo_txt:
22     texto = arquivo_txt.read()
23
24 adverbios = extrair_adverbios(texto)
25
26 frequencia = contar_frequencia(adverbios)
27
28 top_20 = frequencia.most_common(20)
29
30 criar_csv(top_20, 'resultado.csv')
31
```

Este programa em Python permite extrair os 20 advérbios mais frequentes da obra em formato TXT e *one sentence per line*, gerando por fim um arquivo CSV com os resultados. Primeiro, o código lê o arquivo de texto e extrai os advérbios usando expressões regulares. Em seguida, conta a frequência de cada advérbio utilizando a biblioteca *Counter*. Depois disso, seleciona os 20 advérbios mais comuns e cria um arquivo CSV com duas colunas: "Adverbio" e "Frequência". Por fim, o código salva o arquivo CSV com os resultados:

1	Adverbio	Frequencia						
2	justamente	8						
3	verdadeiramente	6						
4	maquinalmente	6						
5	naturalmente	5						
6	realmente	5						
7	finalmente	4						
8	solenemente	4						
9	perfeitamente	4						
10	aceleradamente	4						
11	somente	4						
12	insensivelmente	4						
13	especialmente	3						
14	imediatamente	3						
15	seriamente	3						
16	Naturalmente	3						
17	brevemente	3						
18	voluntariamente	3						
19	cortesmente	3						
20	particularmente	3						
21	ironicamente	3						

Como proposta de visualização, uma vez que os dados não precisam de qualquer limpeza:

Frequencia em comparação com Adverbio



Percebe-se que, na obra, não é muito utilizado o uso de advérbios sendo que o mais utilizado apenas surge oito vezes.

4.3 Verbos

Ainda para esta obra, foi relevante extrair um top dos 20 verbos que surgem com mais frequência na obra. Então, foi criado o seguinte programa:

```
1 import spacy
2 import os
3 import csv
4 from collections import Counter
5
6 with open('onde_esta_a_felicidade1.txt', 'r', encoding='UTF-8') as file:
7     text = file.read()
8
9 nlp = spacy.load('pt_core_news_sm')
10 doc = nlp(text)
11
12 dicionario = dict()
13
14 for token in doc:
15     if token.pos_ == "VERB":
16         if token.lemma_ in dicionario.keys():
17             dicionario[token.lemma_] += 1
18         else:
19             dicionario[token.lemma_] = 1
20
21 verb_counts = Counter(dicionario)
22 top20_verbs = verb_counts.most_common(20)
23
24 print(top20_verbs)
25
26 with open('VERBOSondeestaafelicidade.csv', 'w', newline='') as file:
27     writer = csv.writer(file)
28     writer.writerow(['Verbo', 'Contagem'])
29
30     for verb, count in top20_verbs:
31         writer.writerow([verb, count])
32
33
```

O código realiza uma análise de verbos usando a biblioteca Spacy, com o modelo de linguagem em português. Ele conta a frequência de ocorrência de cada verbo no texto e imprime os 20 verbos mais frequentes. Além disso, os resultados são salvos em um arquivo CSV com duas colunas: "Verbo" e "Contagem". Em seguida, um dicionário vazio é criado para armazenar os verbos e as suas contagens.

O loop percorre cada token no documento e verifica se esse token é um verbo. Se for, o lema do verbo é adicionado ao dicionário, aumentando sua contagem de ocorrência. Se o verbo já estiver presente no dicionário, sua contagem é atualizada. Caso contrário, o verbo é adicionado ao dicionário com uma contagem inicial de 1.

A biblioteca `Counter` é usada para contar a frequência dos verbos no dicionário. Os 20 verbos mais comuns são selecionados usando o método `most_common(20)` e armazenados na lista `top20_verbs`. A lista extraída é a seguinte:

1	Verbo	Contagem							
2	dizer	458							
3	ter	414							
4	querer	271							
5	fazer	252							
6	poder	241							
7	saber	241							
8	dar	187							
9	haver	153							
10	vir	151							
11	ver	146							
12	ser	142							
13	dever	113							
14	falar	94							
15	ir	85							
16	entrar	85							
17	parecer	81							
18	deixar	80							
19	conhecer	77							
20	sair	74							
21	passar	68							
--									

Neste caso, não efetuei qualquer tipo de limpeza uma vez que os dados se revelaram bastante precisos. Então, como proposta de visualização realizou-se uma wordcloud, através de um programa python:

```

1 import matplotlib.pyplot as plt
2 from wordcloud import WordCloud
3
4 texto = "dizer ter querer fazer poder saber dar haver vir ver ser dever falar ir entrar parecer deixar
5 conhecer sair passar."
6
7 wordcloud = WordCloud().generate(texto)
8
9 plt.imshow(wordcloud, interpolation='bilinear')
10 plt.axis('off')
11 plt.show()

```

O resultado foi o seguinte:



Ademais, foi feito também um gráfico de barras:



4.4 Análise de Sentimento

Por fim, para fazer a análise de sentimento de cada capítulo, criei o seguinte programa Python, que utiliza a biblioteca NLTK (Natural Language Toolkit) para realizar uma análise de sentimentos num dado texto. Ele utiliza o módulo `SentimentIntensityAnalyzer` do NLTK, que é responsável por atribuir pontuações de sentimento a diferentes partes do texto.

```
1 import nltk
2 from nltk.sentiment import SentimentIntensityAnalyzer
3
4 nltk.download('vader_lexicon')
5
6 sia = SentimentIntensityAnalyzer()
7
8 caminho_arquivo = "onde_esta_a_felicidade1spl.txt"
9
10 with open(caminho_arquivo, 'r', encoding='utf-8') as arquivo:
11     texto = arquivo.read()
12
13 capitulos = texto.split('# Capítulo')
14
15 for i, capitulo in enumerate(capitulos[1:]):
16     sentiment = sia.polarity_scores(capitulo)
17     print(f"Sentimento do Capítulo {i+1}: {sentiment}")
18
```

Primeiro, o código importa as bibliotecas necessárias e faz o download do léxico Vader do NLTK, que é usado para análise de sentimentos. Em seguida, é criada uma instância do `SentimentIntensityAnalyzer`.

Depois, o código lê o arquivo txt da obra *Onde está a felicidade?* no formato de one sentence per line e armazena-o numa variável. O texto é dividido em capítulos usando um marcador específico (no caso, foi colocada um # em cada capítulo no documento de texto). Através de um loop, cada capítulo é analisado usando o 'SentimentIntensityAnalyzer', que retorna uma pontuação de sentimento para aquele capítulo.

Em resumo, o código realiza a análise de sentimentos no texto, dividindo-o em capítulos e calculando a pontuação de sentimento para cada um deles. Os resultados no terminal são:

```
Sentimento do Capítulo 1: {'neg': 0.02, 'neu': 0.962, 'pos': 0.018, 'compound': 0.695}
Sentimento do Capítulo 2: {'neg': 0.017, 'neu': 0.973, 'pos': 0.01, 'compound': -0.8758}
Sentimento do Capítulo 3: {'neg': 0.011, 'neu': 0.986, 'pos': 0.003, 'compound': -0.9007}
Sentimento do Capítulo 4: {'neg': 0.016, 'neu': 0.976, 'pos': 0.008, 'compound': -0.8238}
Sentimento do Capítulo 5: {'neg': 0.011, 'neu': 0.976, 'pos': 0.013, 'compound': 0.8698}
Sentimento do Capítulo 6: {'neg': 0.004, 'neu': 0.98, 'pos': 0.015, 'compound': 0.9841}
Sentimento do Capítulo 7: {'neg': 0.018, 'neu': 0.962, 'pos': 0.02, 'compound': 0.9444}
Sentimento do Capítulo 8: {'neg': 0.021, 'neu': 0.946, 'pos': 0.033, 'compound': 0.9869}
Sentimento do Capítulo 9: {'neg': 0.007, 'neu': 0.97, 'pos': 0.023, 'compound': 0.9972}
Sentimento do Capítulo 10: {'neg': 0.009, 'neu': 0.977, 'pos': 0.014, 'compound': 0.7121}
Sentimento do Capítulo 11: {'neg': 0.013, 'neu': 0.951, 'pos': 0.036, 'compound': 0.9954}
Sentimento do Capítulo 12: {'neg': 0.016, 'neu': 0.974, 'pos': 0.01, 'compound': -0.7527}
Sentimento do Capítulo 13: {'neg': 0.012, 'neu': 0.973, 'pos': 0.015, 'compound': 0.9488}
Sentimento do Capítulo 14: {'neg': 0.011, 'neu': 0.965, 'pos': 0.023, 'compound': 0.9764}
Sentimento do Capítulo 15: {'neg': 0.022, 'neu': 0.958, 'pos': 0.02, 'compound': 0.8453}
Sentimento do Capítulo 16: {'neg': 0.019, 'neu': 0.972, 'pos': 0.009, 'compound': -0.9174}
Sentimento do Capítulo 17: {'neg': 0.021, 'neu': 0.966, 'pos': 0.013, 'compound': -0.7374}
Sentimento do Capítulo 18: {'neg': 0.018, 'neu': 0.974, 'pos': 0.009, 'compound': -0.9123}
Sentimento do Capítulo 19: {'neg': 0.015, 'neu': 0.977, 'pos': 0.008, 'compound': -0.8372}
Sentimento do Capítulo 20: {'neg': 0.015, 'neu': 0.979, 'pos': 0.006, 'compound': -0.9554}
Sentimento do Capítulo 21: {'neg': 0.009, 'neu': 0.972, 'pos': 0.019, 'compound': 0.9667}
Sentimento do Capítulo 22: {'neg': 0.021, 'neu': 0.966, 'pos': 0.013, 'compound': -0.814}
Sentimento do Capítulo 23: {'neg': 0.016, 'neu': 0.976, 'pos': 0.008, 'compound': -0.9291}
Sentimento do Capítulo 24: {'neg': 0.013, 'neu': 0.964, 'pos': 0.023, 'compound': 0.9264}
Sentimento do Capítulo 25: {'neg': 0.014, 'neu': 0.968, 'pos': 0.019, 'compound': 0.9608}
Sentimento do Capítulo 26: {'neg': 0.014, 'neu': 0.974, 'pos': 0.012, 'compound': 0.7736}
Sentimento do Capítulo 27: {'neg': 0.025, 'neu': 0.963, 'pos': 0.012, 'compound': -0.9067}
Sentimento do Capítulo 28: {'neg': 0.005, 'neu': 0.971, 'pos': 0.024, 'compound': 0.989}
Sentimento do Capítulo 29: {'neg': 0.018, 'neu': 0.969, 'pos': 0.013, 'compound': -0.5897}
Sentimento do Capítulo 30: {'neg': 0.019, 'neu': 0.972, 'pos': 0.009, 'compound': -0.9839}
```

Tipo de sentimento de cada capítulo com base no valor do compound:

- Capítulo 1: Sentimento positivo (compound: 0.695)
- Capítulo 2: Sentimento negativo (compound: -0.8758)
- Capítulo 3: Sentimento negativo (compound: -0.9007)
- Capítulo 4: Sentimento negativo (compound: -0.8238)
- Capítulo 5: Sentimento positivo (compound: 0.8698)
- Capítulo 6: Sentimento positivo (compound: 0.9841)
- Capítulo 7: Sentimento positivo (compound: 0.9444)
- Capítulo 8: Sentimento positivo (compound: 0.9869)
- Capítulo 9: Sentimento positivo (compound: 0.9972)

- Capítulo 10: Sentimento positivo (compound: 0.7121)
- Capítulo 11: Sentimento positivo (compound: 0.9954)
- Capítulo 12: Sentimento negativo (compound: -0.7527)
- Capítulo 13: Sentimento positivo (compound: 0.9488)
- Capítulo 14: Sentimento positivo (compound: 0.9764)
- Capítulo 15: Sentimento positivo (compound: 0.8453)
- Capítulo 16: Sentimento negativo (compound: -0.9174)
- Capítulo 17: Sentimento negativo (compound: -0.7374)
- Capítulo 18: Sentimento negativo (compound: -0.9123)
- Capítulo 19: Sentimento negativo (compound: -0.8372)
- Capítulo 20: Sentimento negativo (compound: -0.9554)
- Capítulo 21: Sentimento positivo (compound: 0.9667)
- Capítulo 22: Sentimento negativo (compound: -0.814)
- Capítulo 23: Sentimento negativo (compound: -0.9291)
- Capítulo 24: Sentimento positivo (compound: 0.9264)
- Capítulo 25: Sentimento positivo (compound: 0.9608)
- Capítulo 26: Sentimento positivo (compound: 0.7736)
- Capítulo 27: Sentimento negativo (compound: -0.9067)
- Capítulo 28: Sentimento positivo (compound: 0.989)
- Capítulo 29: Sentimento negativo (compound: -0.5897)
- Capítulo 30: Sentimento negativo (compound: -0.9839)

Para criar uma proposta de visualização, foi criado o seguinte programa:

```

1 import matplotlib.pyplot as plt
2
3 pontuacoes = [
4     {'neg': 0.02, 'neu': 0.962, 'pos': 0.018, 'compound': 0.695},
5     {'neg': 0.017, 'neu': 0.973, 'pos': 0.01, 'compound': -0.8758},
6     {'neg': 0.011, 'neu': 0.986, 'pos': 0.003, 'compound': -0.9807},
7     {'neg': 0.016, 'neu': 0.976, 'pos': 0.008, 'compound': -0.8238},
8     {'neg': 0.011, 'neu': 0.976, 'pos': 0.013, 'compound': 0.8698},
9     {'neg': 0.004, 'neu': 0.98, 'pos': 0.015, 'compound': 0.9841},
10    {'neg': 0.018, 'neu': 0.962, 'pos': 0.02, 'compound': 0.9444},
11    {'neg': 0.021, 'neu': 0.946, 'pos': 0.033, 'compound': 0.9869},
12    {'neg': 0.007, 'neu': 0.97, 'pos': 0.023, 'compound': 0.9972},
13    {'neg': 0.009, 'neu': 0.977, 'pos': 0.014, 'compound': 0.7121},
14    {'neg': 0.013, 'neu': 0.951, 'pos': 0.036, 'compound': 0.9954},
15    {'neg': 0.016, 'neu': 0.974, 'pos': 0.01, 'compound': -0.7527},
16    {'neg': 0.012, 'neu': 0.973, 'pos': 0.015, 'compound': 0.9488},
17    {'neg': 0.011, 'neu': 0.965, 'pos': 0.023, 'compound': 0.9764},
18    {'neg': 0.022, 'neu': 0.958, 'pos': 0.02, 'compound': 0.8453},
19    {'neg': 0.019, 'neu': 0.972, 'pos': 0.009, 'compound': -0.9174},
20    {'neg': 0.021, 'neu': 0.966, 'pos': 0.013, 'compound': -0.7374},
21    {'neg': 0.018, 'neu': 0.974, 'pos': 0.009, 'compound': -0.9123},
22    {'neg': 0.015, 'neu': 0.977, 'pos': 0.008, 'compound': -0.8372},
23    {'neg': 0.015, 'neu': 0.979, 'pos': 0.006, 'compound': -0.9554},
24    {'neg': 0.009, 'neu': 0.972, 'pos': 0.019, 'compound': 0.9697},
25    {'neg': 0.021, 'neu': 0.966, 'pos': 0.013, 'compound': -0.814},
26    {'neg': 0.016, 'neu': 0.976, 'pos': 0.008, 'compound': -0.9201},
27    {'neg': 0.013, 'neu': 0.964, 'pos': 0.023, 'compound': 0.9264},
28    {'neg': 0.014, 'neu': 0.968, 'pos': 0.019, 'compound': 0.9688},
29    {'neg': 0.014, 'neu': 0.974, 'pos': 0.012, 'compound': 0.7736},
30    {'neg': 0.025, 'neu': 0.963, 'pos': 0.012, 'compound': -0.9867},
31    {'neg': 0.005, 'neu': 0.971, 'pos': 0.024, 'compound': 0.989},
32    {'neg': 0.018, 'neu': 0.969, 'pos': 0.013, 'compound': -0.5897},
33    {'neg': 0.019, 'neu': 0.972, 'pos': 0.009, 'compound': -0.9839}
34 ]
35
36 valores_compound = [sentimento['compound'] for sentimento in pontuacoes]
37
38 rotulos = [f"Capítulo {i+1}" for i in range(len(pontuacoes))]
39
40 plt.figure(figsize=(10, 6))
41 plt.bar(rotulos, valores_compound)
42 plt.xlabel('Capítulo')
43 plt.ylabel('Sentimento (compound)')
44 plt.title('Análise de Sentimento por Capítulo')
45 plt.xticks(rotation=45)
46 plt.show()
47


```

O código em questão utiliza a biblioteca Matplotlib em conjunto com os resultados da análise de sentimento por capítulos para criar um gráfico de barras. O objetivo é visualizar a variação do sentimento ao longo dos capítulos de uma obra. Inicialmente, os resultados da análise de sentimento por capítulo são armazenados numa lista chamada `'pontuacoes'`. Cada elemento dessa lista é um dicionário que contém as pontuações de negatividade (`'neg'`), neutralidade (`'neu'`), positividade (`'pos'`) e a pontuação geral do sentimento (`'compound'`) para um capítulo específico.

O próximo passo consiste em extrair os valores do `'compound'` de cada dicionário da lista `'pontuacoes'`. Esses valores são armazenados numa lista separada chamada `'valores_compound'`. Esta lista representa a medida agregada do sentimento para cada capítulo. A lista `'rotulos'` é criada para armazenar os rótulos dos capítulos. Cada rótulo é definido como "Capítulo X", onde X é o número do capítulo correspondente. Com todos os dados necessários preparados, o código utiliza a biblioteca Matplotlib para criar o gráfico de barras. É criada uma figura com um tamanho específico utilizando a função `'plt.figure(figsize=(10, 6))'`. Em seguida, a função `'plt.bar()'` é utilizada para criar as barras do gráfico. Os rótulos dos capítulos são exibidos no eixo x e os valores do compound são representados no eixo y. Algumas funções do Matplotlib, como `'plt.xlabel()'`, `'plt.ylabel()'`, `'plt.title()'` e `'plt.xticks(rotation=45)'`, são utilizadas para adicionar rótulos aos eixos e ao gráfico em geral, além de fazer uma rotação de 45 graus

nos rótulos dos capítulos para facilitar a leitura. Por fim, o gráfico é exibido na tela utilizando a função `plt.show()`.

Assim, o gráfico:



Conclusão

Ao analisar e avaliar as obras de Camilo Castelo Branco, observa-se que o sentimento predominante das suas obras é geralmente negativo. Através de uma profunda exploração da condição humana, o autor retrata temas como o sofrimento, a tragédia, a melancolia e os conflitos internos das personagens. As suas narrativas mergulham em dilemas morais, paixões não correspondidas, traições e destinos trágicos, criando um ambiente carregado de emoções negativas. Ademais, a análise e visualização de dados traz uma dimensão adicional à literatura, promovendo uma compreensão mais profunda e uma conexão mais significativa entre os escritores, os investigadores e, claro, os leitores. Estas ferramentas auxiliam no desenvolvimento e evolução da literatura, tornando-a mais dinâmica, relevante e impactante no contexto contemporâneo.

Bibliografia

OpenAI. (2022). ChatGPT – OpenAI

<https://chat.openai.com/>

NLTK 2023, NLTK Project

<https://www.nltk.org/>

Hutto, C.J., & Gilbert, E. (2014). vaderSentiment: VADER Sentiment Analysis. Versão 3.3.2 [Software]

<https://pypi.org/project/vaderSentiment/>

Github Inês Leão

<https://github.com/inesctleao/avd2023/tree/main>